

リザーバー計算機における普遍性と 高次統計量

春名 純一
(京都大学)

2021/9/22 @ 日本物理学会秋季大会

Based on arXiv:2110:XXXXX with R.Toshio and N.Nakano

リザーバー計算機とは？

- 再帰的ニューラルネットワークの一つ
Jaeger2001(機械学習), Maass2002(神経科学)が独立に提案
- 時間発展方程式

$$\frac{d\vec{r}(t)}{dt} = -\vec{r}(t) + J\phi(\vec{r}(t)) + W\vec{x}(t) + \vec{b}$$

$\vec{r}(t) \cdots N$ 次元ベクトル

$J \cdots$ ランダム $N \times N$ 行列


$\phi(\cdot) \cdots$ 活性化関数

$W \cdots$ ランダム $N \times N_{in}$ 行列

$\vec{u}(t) \cdots N_{in}$ 次元ベクトル(入力)





$\vec{b} \cdots N$ 次元ランダムベクトル(バイアス)

$\vec{r}(t=0) \cdots$ ランダム N 次元ベクトル



リザーバー計算機でできること

- 時系列予測に利用可
 - e. g) ローレンツカオスの x 座標を入力として $\hat{s}(t) = W_{out}r(t)$ から y, z 座標を予測させる
($W_{out} \cdots N_{out} \times N$ 行列, 唯一の学習パラメータ)



背景

- ノード数 N を大きくすればリザー計算機の計算性能は上がると言われている
- N が十分大きいときどんな関数でも近似可(万能近似定理)
[L. Grigoryeva, J. Ortega 2018]
- 一方, スピングラス模型の一種(Sherrington-Kirkpatrick 模型)との類似が指摘
[J. Schuecker, S. Goedeke, M. Helias 2018]等

$$H = \sum_{i \neq j} J_{ij} s_i s_j \quad (s_i = \pm 1)$$

[D. Sherrington, S. Kirkpatrick 1975]

疑問と動機

- 統計力学と同様に $N = \infty$ 極限 (熱力学極限) で普遍的構造が現れるか
- 計算性能がネットワーク構造 (結合行列の分布関数や活性化関数) にどう依存するか
- 計算性能の向上を統計力学的な観点 (普遍性や相転移など) から理解できるか

を調べたい

やったこと

- $N = \infty$ でのダイナミクスが結合定数の確率分布に対して

$$K(q) = \lim_{N \rightarrow \infty} N K_J(q; \theta(N))$$

という関数を通してのみ依存することを示した

($K_J \cdots J$ の従う確率分布の第二種キュムラント母関数)

- 有効的な時間発展方程式

$$\begin{aligned} \frac{d\vec{r}(t)}{dt} &= -\vec{r}(t) + J\phi(\vec{r}(t)) + \vec{b}_{\text{ext}} \\ \Rightarrow \frac{d\vec{r}_i(t)}{dt} &= -\vec{r}_i(t) + \eta(t) + (\vec{b}_{\text{ext}})_i \end{aligned}$$

- ノイズ項 $\eta(t)$ の相関は

$$\langle \eta(t_1) \cdots \eta(t_n) \rangle = i^{-n} K^{(n)}(0) \langle \phi(r(t_1)) \cdots \phi(r(t_n)) \rangle$$

分布関数の普遍類

- いくつかの確率分布で $K(q)$ は同じ関数形になる
- $N = \infty$ でのダイナミクスは $K(q)$ により分類できる(普遍類)

名前	$K(q)$	N 依存性	具体例
デルタ類	$i\bar{\mu}q$	$E(J) = \frac{\bar{\mu}}{N}$	デルタ, 指数, ガンマ, 対数正規
ガウス類	$i\bar{\mu}q - \frac{\bar{\sigma}^2 q^2}{2}$	$E(J) = \frac{\bar{\mu}}{N}, V(J) = \frac{\bar{\sigma}^2}{N}$	ガウス, 直角三角, 一様, ガンベル
安定類	$i\bar{\delta}q - \bar{\gamma} q ^\alpha \times$ $(1 + i\beta \text{sgn}(q)\omega(q, \alpha))$	$\delta = \frac{\bar{\delta}}{N}, \gamma = \frac{\bar{\gamma}}{N}$	安定
ガンマ類	$-\bar{k} \log(1 - i\theta q)$	$k = \frac{\bar{k}}{N}$	ガンマ


$$\left(\omega(q, 1) = \frac{2}{\pi} \log|q|, \omega(q, \alpha \neq 1) = \tan \frac{\pi\alpha}{2} \right)$$

計算手順(概要)

多体問題→一体問題
相互作用→ノイズ


時間発展方程式

$$\frac{d\vec{r}(t)}{dt} = -\vec{r}(t) + J\phi(\vec{r}(t)) + \vec{b}_{\text{ext}}$$



有効的な時間発展方程式


$$\frac{d\vec{r}_i(t)}{dt} = -\vec{r}_i(t) + \eta(t) + (\vec{b}_{\text{ext}})_i$$



MSRDJ経路積分

経路積分表示

$$Z = \int Dr D\hat{r} [dJ_{ij}] e^{iS}$$



$N = \infty$ での鞍点近似
ノイズを導入

MSRDJ経路積分



有効的な経路積分表示

$$Z = \left\langle \left(\int Dr D\hat{r} e^{iS_1 + i\hat{r}\eta} \right)^N \right\rangle_\eta$$

中心極限定理との違い

- 今回の極限は中心極限定理とは別物
 - 中心極限定理: $K(q) = \lim_{N \rightarrow \infty} NK_J\left(\frac{q}{\sqrt{N}}; \theta\right)$
パラメータは N に依存しない
 - 今回: $K(q) = \lim_{N \rightarrow \infty} NK_J(q; \theta(N))$
パラメータは N に依存する
- 特徴的な例: ガンマ分布 ($K(q) = -\bar{k} \log(1 - i\theta q)$)
平均と分散は有限だが正規分布とは別の普遍類
- 一般の普遍類では高次統計量(キュムラント)が現れる

固有値分布と普遍類

[H. Sommers *et al.*, 1988]

- ランダム行列 J の固有値分布 $\rho(\omega)$ は 2次元空間内の
静電ポテンシャル


$$\Psi(\omega) = -\frac{1}{N} \langle \log \det[(\omega^* I_N - J^T)(\omega I_N - J)] \rangle_J$$

を形成する電荷分布として記述できる:

$$\nabla^2 \Psi(\omega) = -4\pi \rho(\omega) \quad (\omega = x + iy)$$


- Ψ は $N \rightarrow \infty$ で $K(q)$ だけに依存
 $\Rightarrow$ 今回の普遍類は固有値分布と一対一に対応

数値計算(固有値分布)



ガウス類(正規分布)

- Girkoの円則に従う/従わない
- 先行研究はほぼガウス類のみ



ガンマ類(ガンマ分布)

$$\begin{aligned} E[J_{ij}] &= 1.5/N \\ V[J_{ij}] &= 1/N \\ N &= 100, 1000\text{ens} \end{aligned}$$





数値計算(相図と信号分離)

- 定常状態のリザーバー状態相図
 - SK模型と対応
 - 高次統計量は相図を変える

$$E[J_{ij}] = J_0/N$$

$$V[J_{ij}] = J^2/N$$

- ノイズ-信号分離のMSE相図
 - ローレンツ+ノイズ → ローレンツ
 - カオスの縁での性能向上
 - 計算性能に大きな差は出ない



まとめ

- リザーバー計算機のサイズ N が非常に大きいときのダイナミクスを調べた
- 結合定数の分布関数について、同一のダイナミクスを示すいくつかのクラスに分類できる(普遍類)
- 一般の普遍類では高次統計量が現れる
- 同じ普遍類に属するランダム行列は $N \rightarrow \infty$ にて同じ固有値分布をもつ

今後の展望



- 今回話せなかった内容
 - 理論: スパースネットワークへの拡張, 固定点周りでの安定性, くりこみ群によるパラメータの N 依存性の決定方法, スペクトル半径による規格化
 - 数値計算: ローレンツ時系列予測のMSE相図, Memory Capacity相図, 共通入力同期相図
- 今後の課題
 - 計算性能とカオスの縁および臨界点との関係
 - 高次統計量が重要になるタスク
 - ランダム行列の固有値分布の具体的な関数形

Thank you!

バックアップ

時系列予測のMSE相図

- 時系列予測の平均二乗誤差(MSE)の相図




SK模型(スピングラス)

[D.Sherrington, S.Kirkpatrick 1975]

- Sherrington-Kirkpatrick模型(SK模型)

$$H = \sum_{i \neq j} J_{ij} s_i s_j \quad (s_i = \pm 1)$$

- J_{ij} は平均が J_0/N , 分散が J^2/N の正規分布に従う
- 相図は






$N \dots$ サイト数

P ... 常磁性相
F ... 強磁性相
SG... スピングラス相



MSE相図とSK模型相図

- MSE相図(左)とSK模型の相図(右)



数値計算

- ノイズ-信号分離



経路積分表示での生成汎関数

$$Z = \int Dr D\hat{r} [dJ_{ij}] \exp \left(iS + \int dt \sum_i \hat{b}_i r_i \right)$$
$$S = \int_0^\infty dt \sum_i \hat{r}_i \left(-\frac{d}{dt} r_i - r_i + \sum_j J_{ij} \phi(r_j) + b_i \right)$$
$$[dJ_{ij}] = \prod_{i,j} dJ_{ij} P_J(J_{ij})$$

• J_{ij} 積分実行後

$$Z = \int Dr D\hat{r} \exp \left(i\bar{S} + \sum_{i,j} K_J \left(\int dt \hat{r}_i \phi(r_j) \right) + \int dt \sum_i \hat{b}_i r_i \right)$$

$K_J \cdots P_J$ の特性関数の対数 (第二種キュムラント母関数)

$$\bar{S} = S - \sum_{i,j} \int dt \hat{r}_i \phi(r_j)$$

$N \rightarrow \infty$ 極限でのダイナミクス

ダイナミクスは $K(q) := \lim_{N \rightarrow \infty} NK_J(q; \theta(N))$ **でのみ** 決まる
($\theta(N) \dots P_J$ のパラメータ (N に依存))

$$Z = \int DC_n D\hat{C}_n \exp(-NS_1)$$

$$S_1 = -\log \left[\int D\hat{r} Dr \exp \left(i\bar{S}_1 + \int dt \hat{b}_i r \right) \right] + i \sum_{n=1}^{\infty} \int [dt]_n C_n(t_1, \dots, t_n) \hat{C}_n(t_1, \dots, t_n)$$

$$\bar{S}_1 = \int dt \hat{r} \left(-\frac{d}{dt} r - r + b \right) + \sum_{n=1}^{\infty} \int [dt]_n \left(\frac{\kappa_n}{n!} i^n C_n \hat{r}(t_1) \dots \hat{r}(t_n) + \hat{C}_n \phi(r(t_1)) \dots \phi(r(t_n)) \right)$$

$$[dt]_n = \prod_{i=1}^n dt_i, \quad C_n(t_1, \dots, t_n), \hat{C}_n(t_1, \dots, t_n) \dots \text{補助場}$$

$$\kappa_n = i^{-n} \frac{d^n K}{dq^n} \Big|_{q=0} \dots n \text{ 次のキュムラント}$$

スパースネットワークへの拡張

- スパースネットワークでも同様の普遍性が成立
- 結合度 k ... 1つのノードが結合する平均的なノード数

$$k = cN^\alpha \quad (0 < \alpha < 1)$$

(truly sparseの場合($\alpha = 0$)は扱わない)

- J_{ij} の積分測度は有効的に

$$[dJ_{ij}] = \prod_{i,j} dJ_{ij} \left(\left(1 - \frac{k}{N} \right) \delta(J_{ij}) + \frac{k}{N} P_J(J_{ij}) \right)$$

スパースネットワークへの拡張

- 対応する $K(q)$ は

$$K = \lim_{N \rightarrow \infty} N \log \left(1 - \frac{k}{N} + \frac{k}{N} \exp(K_J) \right)$$

- 収束性から $\lim_{N \rightarrow \infty} K_J(q; \theta(N)) = 0$ なので

$$K = \lim_{N \rightarrow \infty} k K_J = c \lim_{N \rightarrow \infty} N^\alpha K_J(q; \theta(N))$$

- 全結合 ($\alpha = 1$) のときのチューニングを $\theta(N)$ とすると
スパースな場合は $\theta(N^\alpha)$ と決まる
 $\Rightarrow$ 全結合と同じ普遍類で分類

スペクトル半径での規格化

- J_{ij} を以下のように定める

$$J_{ij} = \frac{r}{\rho(J'_{ij})} J'_{ij}$$

J'_{ij} … 確率分布 $P_{J'}(J'_{ij})$ に従う乱数

$\rho(J'_{ij})$ … J'_{ij} のスペクトル半径

- J_{ij} のスペクトル半径は r に規格化
- $N \rightarrow \infty$ で J_{ij} が どんな確率分布に従うか?

スペクトル半径での規格化

- $N \rightarrow \infty$ での振る舞いは

$$\rho(J'_{ij}) \sim c \sqrt{N}$$

と期待される

(e.g. J'_{ij} が実対称 $\Rightarrow$ Wignerの半円則($c = 2\sigma$))

- 対応する $K(q)$ は

$$K(q) = \lim_{N \rightarrow \infty} N K_{J'} \left(\frac{r}{\rho(J'_{ij})} q \right) = \lim_{N \rightarrow \infty} N K_{J'} \left(\frac{r}{c \sqrt{N}} q \right)$$

$\Rightarrow$ 中心極限定理と本質的に同じ